

## 第二章 参数估计

## 一.分类

(一)非参数估计问题：总体的分布类型未知，需要由样本构造统计量去估计总体的分布函数或密度函数。

(二)参数估计问题：总体分布类型已知，其中含有未知参数，需由样本构造统计量来估计未知参数。

**例1.**学生的成绩 $X \sim N(\mu, \sigma^2)$ , 但参数 $\mu, \sigma^2$ 未知, 需通过样本来估计。

**例2.**已知某城市在单位时间内发生交通事故的次数 $X \sim P(\lambda)$ , 但 $\lambda$ 未知, 需通过样本来估计。

## 二.对于参数估计, 按问题的性质不同分为两类

1.点估计: 适当的选择一个统计量 $\hat{\theta}(X_1, \dots, X_n)$ 作为未知参数 $\theta$ 的估计.

2.区间估计: 求未知参数 $\theta$ 的范围, 即求一个区间使以较大的概率包含未知参数.

## 第一节 矩估计和极大似然估计

# 第一节 矩估计和极大似然估计

一.矩估计：用样本 $k$ 阶矩作为总体 $k$ 阶矩的估计量，建立含有待估参数的方程，从而解出待估参数.

(一)矩估计的思想：实质是由辛钦大数定律，设 $\xi_1, \xi_2, \dots, \xi_n, \dots$ 是相互独立同分布的随机变量，且 $E\xi_i^k, i = 1, 2, \dots$ 存在，则

$$\lim_{n \rightarrow \infty} P(|\frac{1}{n} \sum_{i=1}^n \xi_i^k - E\xi_i^k| \geq \epsilon) = 0.$$

所以可用样本矩代替总体矩，求得未知参数 $\theta$ ，即替换原则。

# 第一节 矩估计和极大似然估计

(二)矩估计的方法: 设 $X \sim F(x; \theta)$ ,  $\theta = (\theta_1, \dots, \theta_k)$ 是未知参数向量, 若 $F(x; \theta)$ 的 $k$ 阶矩存在,

$$\alpha_\nu(\theta) = \int_{-\infty}^{\infty} x^\nu dF(x; \theta), \quad 1 \leq \nu \leq k$$

是 $\theta = (\theta_1, \dots, \theta_k)$ 的函数. 设 $(X_1, \dots, X_n)$ 是取自总体 $X$ 的一个样本, 则由下列方程组

$$\begin{cases} \frac{1}{n} \sum_{i=1}^n X_i = \alpha_1(\theta_1, \dots, \theta_k); \\ \frac{1}{n} \sum_{i=1}^n X_i^2 = \alpha_2(\theta_1, \dots, \theta_k); \\ \vdots \\ \frac{1}{n} \sum_{i=1}^n X_i^k = \alpha_k(\theta_1, \dots, \theta_k), \end{cases}$$

得到 $\theta = (\theta_1, \dots, \theta_k)$ 的一组解 $\hat{\theta} = (\hat{\theta}_1, \dots, \hat{\theta}_k)$ , 其中 $\hat{\theta}_\nu = \hat{\theta}_\nu(X_1, \dots, X_n)$ , 并以 $\hat{\theta}_\nu$ 作为参数 $\theta_\nu$ 的估计量,  $\nu = 1, \dots, k$ , 则称 $\hat{\theta}_\nu$ 为未知参数 $\theta_\nu$ 的矩估计量.

# 第一节 矩估计和极大似然估计

**例1:**求总体 $X$ 的均值 $EX = \mu$ 和方差 $DX = \sigma^2$ 的矩估计.

解:  $(X_1, \dots, X_n)$ 是取自总体 $X$ 的一个样本,若总体的二阶矩 $\alpha_2$ 存在,则有 $\alpha_2 = \sigma^2 + \mu^2$ ,

$$\begin{cases} \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i = \mu; \\ \frac{1}{n} \sum_{i=1}^n X_i^2 = \alpha_2 = \mu^2 + \sigma^2. \end{cases}$$

以此方程组的解作为 $\mu, \sigma^2$ 的估计

$$\begin{aligned} \hat{\mu} &= \bar{X}; \\ \hat{\sigma}^2 &= \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \tilde{S}^2. \end{aligned}$$

所以,总体均值 $\mu$ 和方差 $\sigma^2$ 的矩估计,分别是样本均值 $\bar{X}$ 和样本二阶中心矩 $\tilde{S}^2$ . 这个结论对任何总体都成立.

# 第一节 矩估计和极大似然估计

**例2:** 设 $X$ 的密度函数为 $f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0 \end{cases}$

解:  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i = EX = \frac{1}{\lambda}$ , 所以 $\hat{\lambda} = \frac{1}{\bar{X}}$ 为 $\lambda$ 的矩估计.



# 第一节 矩估计和极大似然估计

**例3:** 设  $X \sim U(\theta_1, \theta_2)$ , 其概率密度函数为

$$f(x; \theta_1, \theta_2) = \begin{cases} \frac{1}{\theta_2 - \theta_1}, & \theta_1 < x < \theta_2; \\ 0, & \text{其它}, \end{cases}$$

其中  $\theta_1 < \theta_2$ , 求  $\theta = (\theta_1, \theta_2)$  的矩估计.

**解:** 由均匀分布  $U(\theta_1, \theta_2)$  的性质, 有  $EX = \frac{\theta_1 + \theta_2}{2}$ ,  $DX = \frac{(\theta_2 - \theta_1)^2}{12}$ .  
因此可得方程组

$$\begin{cases} \bar{X} = \frac{\theta_1 + \theta_2}{2}; \\ \tilde{S}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{(\theta_2 - \theta_1)^2}{12}. \end{cases}$$

以此方程组的解作为  $\theta_1, \theta_2$  的估计, 得

$$\begin{cases} \hat{\theta}_1 = \bar{X} - \sqrt{3}\tilde{S}; \\ \hat{\theta}_2 = \bar{X} + \sqrt{3}\tilde{S}, \end{cases}$$

此即所求的  $\theta_1, \theta_2$  的矩估计.

# 第一节 矩估计和极大似然估计

例4: 设  $X \sim \Gamma(\alpha, \beta)$ ,  $\alpha > 0, \beta > 0$ , 即密度函数为

$$f(x; \alpha, \beta) = \begin{cases} \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

求  $\alpha, \beta$  的矩估计.

解: 由  $\Gamma$  分布的性质,  $EX = \frac{\alpha}{\beta}$ ,  $DX = \frac{\alpha}{\beta^2}$ , 因此可得方程组

$$\begin{cases} \bar{X} = \frac{\alpha}{\beta}; \\ \tilde{S}^2 = \frac{\alpha}{\beta^2}. \end{cases}$$

得

$$\begin{cases} \hat{\alpha} = \frac{\bar{X}^2}{\tilde{S}^2}; \\ \hat{\beta} = \frac{\bar{X}}{\tilde{S}^2}. \end{cases}$$

# 第一节 矩估计和极大似然估计

注：(1)矩估计直观简便

(2)要求总体的原点矩存在，若不存在则不能用，如柯西分布

(3)没有充分利用 $F(x; \theta)$ 对 $\theta$ 所提供的信息

# 第一节 矩估计和极大似然估计

## 二.极大似然估计

**(一)原理：**极大似然估计是建立在极大似然原理基础之上。

**引例.** 两外形相同的箱子，各装100个球，其中第一箱有99个白球和1个红球，第二箱有1个白球和99个红球，现从两箱中任取一箱，并从箱中任取一球，所取球为白球，问所取球来自哪一箱。

**例1:** 设总体  $X \sim b(1, p)$ ,  $P\{X = 1\} = p$ , 采用上述思路(极大似然估计的思想)求  $p$  的估计值.

**注：** 概率最大的事件最可能发生

# 第一节 矩估计和极大似然估计

(二)定义: 设 $(X_1, \dots, X_n)$ 为取自具有概率分布族 $\{f(x; \theta) : \theta \in \Theta\}$ 的离散型总体 $X$ 的一个样本, 其中 $\theta = (\theta_1, \dots, \theta_k)$ 是未知的 $k$ 维参数向量,  $(X_1, \dots, X_n)$ 取观测值 $(x_1, \dots, x_n)$ 的概率为

$$L(x_1, \dots, x_n; \theta) \triangleq \prod_{i=1}^n f(x_i; \theta),$$

$L(x_1, \dots, x_n; \theta)$ 称为 $\theta$ 的似然函数(Likelihood Function). 若 $\hat{\theta}$ 使

$$L(x_1, \dots, x_n; \hat{\theta}) = \sup_{\theta \in \Theta} L(x_1, \dots, x_n; \theta)$$

并以 $\hat{\theta}$ 作为参数 $\theta$ 的估计值, 则称 $\hat{\theta}$ 为 $\theta$ 的极大似然估计值, 其相应的统计量 $\hat{\theta}(X_1, \dots, X_n)$ 称为 $\theta$ 的极大似然估计量. 简记为MLE或ML估计.

# 第一节 矩估计和极大似然估计

## (三)求极大似然估计的方法

(1)先求似然函数 $L(x_1, \dots, x_n; \theta) \triangleq \prod_{i=1}^n f(x_i; \theta) \triangleq L(\theta)$

(2)因为 $L(\theta)$ 与 $\ln L(\theta)$ 有相同的极大值点, 所以 $\ln L(\hat{\theta}) = \sup_{\theta \in \Theta} \ln L(\theta)$ , 若 $L$ 可微,  $\ln L(\theta)$ 关于 $\theta_1, \dots, \theta_k$ 分别求导数, 并令其等于0, 得 $\frac{\partial \ln L(\theta)}{\partial \theta_i} = 0, i = 1, \dots, k$ , 称为似然方程组; 求解方程组, 得 $\hat{\theta}$ 并证明 $\hat{\theta}$ 使 $L(\theta)$ 达到最大,  $\hat{\theta}$ 即为 $\theta$ 的极大似然估计;

若 $L$ 不可微, 则用其他方法求出极大似然估计值.

# 第一节 矩估计和极大似然估计

**例2:** 设 $X$ 的密度函数为 $f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0 \end{cases}$ , 求参数 $\lambda$ 的极大似然估计。

解: 设 $(x_1, \dots, x_n)$ 是样本 $(X_1, \dots, X_n)$ 的一组观测值, 似然函数为

$$L(x_1, \dots, x_n; \lambda) = \prod_{i=1}^n f(x_i; \lambda) = \prod_{i=1}^n \lambda e^{-\lambda x_i} = \lambda^n e^{-\lambda \sum_{i=1}^n x_i}$$

则 $\ln L(x_1, \dots, x_n; \lambda) = n \ln \lambda - \lambda \sum_{i=1}^n x_i$

$$\text{令 } \frac{\partial \ln L}{\partial \lambda} = \frac{n}{\lambda} - \sum_{i=1}^n x_i = 0$$

经验证,  $\hat{\lambda} = \frac{1}{\bar{X}}$  是 $\lambda$ 的极大似然估计。

# 第一节 矩估计和极大似然估计

**例2:** 设 $X$ 的密度函数为 $f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0 \end{cases}$ , 求参数 $\lambda$ 的极大似然估计。

**解:** 设 $(x_1, \dots, x_n)$ 是样本 $(X_1, \dots, X_n)$ 的一组观测值, 似然函数为

$$L(x_1, \dots, x_n; \lambda) = \prod_{i=1}^n f(x_i; \lambda) = \prod_{i=1}^n \lambda e^{-\lambda x_i} = \lambda^n e^{-\lambda \sum_{i=1}^n x_i}$$

$$\text{则 } \ln L(x_1, \dots, x_n; \lambda) = n \ln \lambda - \lambda \sum_{i=1}^n x_i$$

$$\text{令 } \frac{\partial \ln L}{\partial \lambda} = \frac{n}{\lambda} - \sum_{i=1}^n x_i = 0$$

经验证,  $\hat{\lambda} = \frac{1}{\bar{X}}$  是 $\lambda$ 的极大似然估计。



# 第一节 矩估计和极大似然估计

**例3:** 设总体 $X$ 具有均匀分布, 密度函数为

$$f(x, \theta) = \begin{cases} \frac{1}{\theta}, & 0 < x < \theta; \\ 0, & \text{其它}, \end{cases}$$

其中 $\theta > 0$ 是未知参数, 求 $\theta$ 的极大似然估计.

解: 设 $(x_1, \dots, x_n)$ 是样本 $(X_1, \dots, X_n)$ 的一组观测值, 似然函数为

$$L(\theta) = \begin{cases} \frac{1}{\theta^n}, & 0 < x_i < \theta; \\ 0, & \text{其它}, \end{cases}$$

要使 $L$ 最大, 必须使 $\theta$ 最小, 当 $\theta = \max_{1 \leq i \leq n} x_i = x_{(n)}$ 时, 可使 $L$ 最大, 故 $\hat{\theta} = X_{(n)}$ 为参数 $\theta$ 的极大似然估计量.

# 第一节 矩估计和极大似然估计

**例3:** 设总体 $X$ 具有均匀分布, 密度函数为

$$f(x, \theta) = \begin{cases} \frac{1}{\theta}, & 0 < x < \theta; \\ 0, & \text{其它}, \end{cases}$$

其中 $\theta > 0$ 是未知参数, 求 $\theta$ 的极大似然估计.

**解:** 设 $(x_1, \dots, x_n)$ 是样本 $(X_1, \dots, X_n)$ 的一组观测值, 似然函数为

$$L(\theta) = \begin{cases} \frac{1}{\theta^n}, & 0 < x_i < \theta; \\ 0, & \text{其它}, \end{cases}$$

要使 $L$ 最大, 必须使 $\theta$ 最小, 当 $\theta = \max_{1 \leq i \leq n} x_i = x_{(n)}$ 时, 可使 $L$ 最大, 故 $\hat{\theta} = X_{(n)}$ 为参数 $\theta$ 的极大似然估计量.

# 第一节 矩估计和极大似然估计

**例4:** 设总体  $X \sim N(\mu, \sigma^2)$ , 其中  $\theta = (\mu, \sigma^2)$  为未知参数向量, 参数空间  $\Theta = \{(\mu, \sigma^2) : -\infty < \mu < \infty, \sigma^2 > 0\}$ , 求  $\mu, \sigma^2$  的极大似然估计.

**解:** 设  $(x_1, \dots, x_n)$  是样本  $(X_1, \dots, X_n)$  的一组观测值, 于是似然函数为

$$L(\mu, \sigma^2) = \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\},$$

两边取对数得

$$l(\mu, \sigma^2) = \log L(\mu, \sigma^2) = -\frac{n}{2} \log 2\pi - \frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2,$$

分别求上式关于  $\mu$  和  $\sigma^2$  的偏导数, 并令它们为 0, 得似然方程组

$$\begin{cases} \frac{\partial \log L}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0; \\ \frac{\partial \log L}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 = 0; \end{cases}$$

# 第一节 矩估计和极大似然估计

**例4:** 设总体  $X \sim N(\mu, \sigma^2)$ , 其中  $\theta = (\mu, \sigma^2)$  为未知参数向量, 参数空间  $\Theta = \{(\mu, \sigma^2) : -\infty < \mu < \infty, \sigma^2 > 0\}$ , 求  $\mu, \sigma^2$  的极大似然估计.

**解:** 设  $(x_1, \dots, x_n)$  是样本  $(X_1, \dots, X_n)$  的一组观测值, 于是似然函数为

$$L(\mu, \sigma^2) = \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\},$$

两边取对数得

$$l(\mu, \sigma^2) = \log L(\mu, \sigma^2) = -\frac{n}{2} \log 2\pi - \frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2,$$

分别求上式关于  $\mu$  和  $\sigma^2$  的偏导数, 并令它们为 0, 得似然方程组

$$\begin{cases} \frac{\partial \log L}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0; \\ \frac{\partial \log L}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 = 0, \end{cases}$$

# 第一节 矩估计和极大似然估计

解之得

$$\begin{cases} \hat{\mu} &= \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}; \\ \hat{\sigma}^2 &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \tilde{s}_n^2. \end{cases}$$

容易验证  $\hat{\mu}, \hat{\sigma}^2$  满足关系式

$$L(\hat{\mu}, \hat{\sigma}^2) = \sup_{-\infty < \mu < \infty, \sigma^2 > 0} L(\mu, \sigma^2),$$

所以  $\bar{X}$  和  $\tilde{S}_n^2$  分别是  $\mu$  和  $\sigma^2$  的极大似然估计.

# 第一节 矩估计和极大似然估计

注：(1)极大似然估计充分利用了总体分布所提供的信息，比矩法估计优，特别是对大样本的情况。

(2)必须知道总体的分布，且有时不易求出极大似然方程组的解。

(3)若函数 $g(\theta)$ 具有单值反函数， $\hat{\theta}$ 是 $\theta$ 的MLE，则 $g(\hat{\theta})$ 是 $g(\theta)$ 的MLE.

## 第二节 估计量的优良性准则

## 第二节 估计量的优良性准则

## 第二节 估计量的优良性准则

### 一. 无偏估计

**1. 定义：** 设总体 $X$ 具有分布族 $\{F(x; \theta) : \theta \in \Theta\}$ ,  $(X_1, \dots, X_n)$ 是取自这个总体的一个样本,  $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$ 是未知参数 $\theta$ 的一个估计量, 如果对于一切 $\theta \in \Theta$ , 都有

$$E_{\theta}[\hat{\theta}(X_1, \dots, X_n)] = \theta$$

则称 $\hat{\theta}(X_1, \dots, X_n)$ 为 $\theta$ 的**无偏估计**, 简记为UE.



## 第二节 估计量的优良性准则

**例1:** 设总体 $X$ 的均值为 $\mu$ , 方差为 $\sigma^2$ ,  $(X_1, \dots, X_n)$ 为取自总体的样本, 则

(1)  $E(\bar{X}) = \mu$ ;

(2) 总体 $X$ 的 $k$ 阶原点矩 $m_k = E(X^k)$ 存在, 则样本 $k$ 阶原点矩 $A_k$ 满足 $E(A_k) = m_k$ .

解: 因为 $E(X_i) = E(X) = \mu$ ,  $D(X_i) = D(X) = \sigma^2$ ,  $i = 1, \dots, n$ , 且 $X_1, \dots, X_n$ 相互独立, 则

$E(\bar{X}) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \frac{1}{n} \sum_{i=1}^n \mu = \mu$ , 所以 $\bar{X}$ 是 $\mu$ 的无偏估计。

$E(A_k) = E(\frac{1}{n} \sum_{i=1}^n X_i^k) = \frac{1}{n} \sum_{i=1}^n E(X_i^k) = m_k$ , 所以 $A_k$ 是 $m_k$ 的无偏估计。

## 第二节 估计量的优良性准则

**例1:** 设总体 $X$ 的均值为 $\mu$ , 方差为 $\sigma^2$ ,  $(X_1, \dots, X_n)$ 为取自总体的样本, 则

(1)  $E(\bar{X}) = \mu$ ;

(2) 总体 $X$ 的 $k$ 阶原点矩 $m_k = E(X^k)$ 存在, 则样本 $k$ 阶原点矩 $A_k$ 满足 $E(A_k) = m_k$ .

**解:** 因为 $E(X_i) = E(X) = \mu$ ,  $D(X_i) = D(X) = \sigma^2$ ,  $i = 1, \dots, n$ , 且 $X_1, \dots, X_n$ 相互独立, 则

$E(\bar{X}) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \frac{1}{n} \sum_{i=1}^n \mu = \mu$ , 所以 $\bar{X}$ 是 $\mu$ 的无偏估计。

$E(A_k) = E(\frac{1}{n} \sum_{i=1}^n X_i^k) = \frac{1}{n} \sum_{i=1}^n E(X_i^k) = m_k$ , 所以 $A_k$ 是 $m_k$ 的无偏估计。

## 第二节 估计量的优良性准则

2. 若  $E(\hat{\theta}) \neq \theta$ , 则称它是有偏的, 且称函数  $b(\theta, \hat{\theta}) = E(\hat{\theta}) - \theta$  为  $\hat{\theta}$  的偏.

3. 若有一列  $\theta$  的估计  $\hat{\theta}_n = \hat{\theta}_n(X_1, \dots, X_n)$ , 对一切  $\theta \in \Theta$  满足  $\lim_{n \rightarrow \infty} E_{\theta}(\hat{\theta}_n) = \theta$ , 即  $\lim_{n \rightarrow \infty} b_n = 0$ , 则称  $\hat{\theta}_n$  为  $\theta$  的渐近无偏估计量。

## 第二节 估计量的优良性准则

例2: (续)

验证  $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ ,  $\tilde{S}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$  是否为  $\sigma^2$  的无偏估计。

解: 由 Th1.2 知  $E(S^2) = \sigma^2$ , 所以  $S^2$  是  $\sigma^2$  的无偏估计。

$E(\tilde{S}^2) = E(\frac{n-1}{n} S^2) = \frac{n-1}{n} \sigma^2 \neq \sigma^2$ , 所以  $\tilde{S}^2$  不是  $\sigma^2$  的无偏估计, 偏为  $E(\tilde{S}^2) - \sigma^2 = (\frac{n-1}{n} - 1) \sigma^2 = -\frac{\sigma^2}{n}$ 。

但  $\lim_{n \rightarrow \infty} E(\tilde{S}_n^2) = \sigma^2$ , 所以  $\tilde{S}^2$  是  $\sigma^2$  的渐近无偏估计。

## 第二节 估计量的优良性准则

例2: (续)

验证  $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ ,  $\tilde{S}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$  是否为  $\sigma^2$  的无偏估计。

解: 由Th1.2知  $E(S^2) = \sigma^2$ , 所以  $S^2$  是  $\sigma^2$  的无偏估计。

$E(\tilde{S}^2) = E(\frac{n-1}{n} S^2) = \frac{n-1}{n} \sigma^2 \neq \sigma^2$ , 所以  $\tilde{S}^2$  不是  $\sigma^2$  的无偏估计, 偏为  $E(\tilde{S}^2) - \sigma^2 = (\frac{n-1}{n} - 1) \sigma^2 = -\frac{\sigma^2}{n}$ 。

但  $\lim_{n \rightarrow \infty} E(\tilde{S}_n^2) = \sigma^2$ , 所以  $\tilde{S}^2$  是  $\sigma^2$  的渐近无偏估计。

## 第二节 估计量的优良性准则

4. 若对 $\theta$ 的任一实值函数 $g(\theta)$ , 如果存在估计量 $T = T(X_1, \dots, X_n)$ , 使得对一切 $\theta \in \Theta$ , 有 $E_{\theta}(T) = g(\theta)$ , 则 $g(\theta)$ 称为可估计函数.

例: 设 $X \sim b(n, p)$ ,  $0 < p < 1$ ,  $X_1$ 是取自这个总体的一个样本, 则函数 $g(p) = \frac{1}{p}$ 不可估.

## 第二节 估计量的优良性准则

**例3:** 设 $(X_1, \dots, X_n)$ 是从正态总体 $N(\mu, \sigma^2)$ 中抽取的一个样本,由定理知 $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$ ,  $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$ . 虽然 $\bar{X}$ 是 $\mu$ 的一个无偏估计,但 $\bar{X}^2$ 不是 $\mu^2$ 的无偏估计,

$$E_{\mu}(\bar{X}^2) = D_{\mu}(\bar{X}) + [E_{\mu}(\bar{X})]^2 = \frac{\sigma^2}{n} + \mu^2 \neq \mu^2.$$

同样,虽然 $S^2$ 是 $\sigma^2$ 的一个无偏估计,但 $S$ 也不是 $\sigma$ 的无偏估计.事实上

$$\begin{aligned} E_{\sigma}(\sqrt{n-1}S/\sigma) &= \int_0^{\infty} \frac{\sqrt{x}}{2^{\frac{n-1}{2}} \Gamma(\frac{n-1}{2})} e^{-\frac{x}{2}} x^{\frac{n-1}{2}-1} dx \\ &= \frac{1}{2^{\frac{n-1}{2}} \Gamma(\frac{n-1}{2})} 2^{\frac{n}{2}} \Gamma(\frac{n}{2}) \\ &= \frac{\sqrt{2} \Gamma(\frac{n}{2})}{\Gamma(\frac{n-1}{2})}, \end{aligned}$$

$$E_{\sigma}(S) = \sigma \left[ \sqrt{\frac{2}{n-1}} \frac{\Gamma(\frac{n}{2})}{\Gamma(\frac{n-1}{2})} \right] \neq \sigma.$$

## 第二节 估计量的优良性准则

可见, $S$ 不是 $\sigma$ 的无偏估计,它的偏为

$$b(\sigma, S) = \sigma \left[ \sqrt{\frac{2}{n-1}} \frac{\Gamma(\frac{n}{2})}{\Gamma(\frac{n-1}{2})} - 1 \right].$$

但容易由这个有偏估计修改得到 $\sigma$ 的无偏估计

$$\hat{\sigma} = \sqrt{\frac{n-1}{2}} \frac{\Gamma(\frac{n-1}{2})}{\Gamma(\frac{n}{2})} S.$$



## 第二节 估计量的优良性准则

注：(1)若 $\hat{\theta}$ 是 $\theta$ 的有偏估计，且 $E(\hat{\theta}) = a + b\theta$  ( $a, b \neq 0$ 为常数)，则可以构造一个 $\theta$ 的无偏估计 $\hat{\theta}^* = \frac{\hat{\theta} - a}{b}$ 。

(2)若 $\hat{\theta}$ 是 $\theta$ 的无偏估计，除了 $f$ 是线性函数外，并不能推出 $f(\hat{\theta})$ 是 $f(\theta)$ 的无偏估计。

## 第二节 估计量的优良性准则

例4. 设总体 $X$ 服从均匀分布, 密度函数为

$$f(x; \theta) = \begin{cases} \frac{1}{\theta}, & 0 < x < \theta; \\ 0, & \text{其它}, \end{cases}$$

$(X_1, \dots, X_n)$ 是取自这个总体的一个样本,

(1)求 $\theta$ 的矩估计, 验证无偏性。

(2)求 $\theta$ 的MLE, 验证无偏性。

解: 由于 $EX = \frac{\theta}{2}$ , 故 $\hat{\theta} = 2\bar{X}$ 是 $\theta$ 的矩估计, 且它是无偏的.

由前知 $\hat{\theta}_L = X_{(n)}$ 是 $\theta$ 的极大似然估计.

$E_{\theta}(\hat{\theta}_L) = \int_0^{\theta} x \cdot \frac{n}{\theta} \left(\frac{x}{\theta}\right)^{n-1} dx = \frac{n}{n+1}\theta$ , 即 $\hat{\theta}_L$ 不是 $\theta$ 的无偏估计, 但 $\hat{\theta}_L$ 是 $\theta$ 的渐近无偏估计.

由 $\hat{\theta}_L = X_{(n)}$ 可以构造 $\theta$ 的一个无偏估计量 $\hat{\theta}^* = \frac{n+1}{n}X_{(n)}$ .

## 第二节 估计量的优良性准则

**例4.** 设总体 $X$ 服从均匀分布,密度函数为

$$f(x; \theta) = \begin{cases} \frac{1}{\theta}, & 0 < x < \theta; \\ 0, & \text{其它}, \end{cases}$$

$(X_1, \dots, X_n)$ 是取自这个总体的一个样本,

(1)求 $\theta$ 的矩估计, 验证无偏性。

(2)求 $\theta$ 的MLE, 验证无偏性。

**解:** 由于 $EX = \frac{\theta}{2}$ ,故 $\hat{\theta} = 2\bar{X}$ 是 $\theta$ 的矩估计,且它是无偏的.

由前知 $\hat{\theta}_L = X_{(n)}$ 是 $\theta$ 的极大似然估计.

$E_{\theta}(\hat{\theta}_L) = \int_0^{\theta} x \cdot \frac{n}{\theta} \left(\frac{x}{\theta}\right)^{n-1} dx = \frac{n}{n+1}\theta$ , 即 $\hat{\theta}_L$ 不是 $\theta$ 的无偏估计,但 $\hat{\theta}_L$ 是 $\theta$ 的渐近无偏估计.

由 $\hat{\theta}_L = X_{(n)}$ 可以构造 $\theta$ 的一个无偏估计量 $\hat{\theta}^* = \frac{n+1}{n}X_{(n)}$ .

## 第二节 估计量的优良性准则

考虑 $\theta$ 的这两个无偏估计量 $\hat{\theta}$ 与 $\hat{\theta}^*$ 的方差,

$$\begin{aligned} D_{\theta}(\hat{\theta}) &= D_{\theta}(2\bar{X}) = 4D_{\theta}(\bar{X}) = \frac{4}{n}D_{\theta}(X) = \frac{\theta^2}{3n}; \\ D_{\theta}(\hat{\theta}_L) &= \int_0^{\theta} x^2 \cdot n \frac{x^{n-1}}{\theta^n} dx - \left(\frac{n}{n+1}\theta\right)^2 \\ &= \frac{n\theta^2}{(n+1)^2(n+2)}, \end{aligned}$$

所以

$$D_{\theta}(\hat{\theta}^*) = D_{\theta}\left(\frac{n+1}{n}\hat{\theta}_L\right) = \frac{(n+1)^2}{n^2}D_{\theta}(\hat{\theta}_L) = \frac{\theta^2}{n(n+2)}.$$

显然,  $D_{\theta}(\hat{\theta}^*) \leq D_{\theta}(\hat{\theta})$ , 而且当  $n$  很大

时, 有  $\lim_{n \rightarrow \infty} \frac{D_{\theta}(\hat{\theta}^*)}{D_{\theta}(\hat{\theta})} = \lim_{n \rightarrow \infty} \frac{3}{n+2} = 0$ . 可见  $\hat{\theta}^*$  和  $\hat{\theta}$  的取值都在参数真值  $\theta$  的周围波动, 但  $\hat{\theta}^*$  比  $\hat{\theta}$  取值更集中, 作为  $\theta$  的估计量,  $\hat{\theta}^*$  比  $\hat{\theta}$  好.

## 第二节 估计量的优良性准则

### 二.一致最小方差无偏估计

1.定义: 设  $T_1(X_1, \dots, X_n)$  为可估函数  $g(\theta)$  的无偏估计量, 若对于任意的  $\theta \in \Theta$  和任意的  $g(\theta)$  的无偏估计量  $T(X_1, \dots, X_n)$ , 都有

$$D_{\theta}[T_1(X_1, \dots, X_n)] \leq D_{\theta}[T(X_1, \dots, X_n)],$$

则称  $T_1(X_1, \dots, X_n)$  是  $g(\theta)$  的一致最小方差无偏估计量, 简记为 UMVUE.

记  $U \triangleq \{T : E_{\theta}(T) = g(\theta), D_{\theta}(T) < \infty, \text{ 对一切 } \theta \in \Theta\}$ , 为可估函数  $g(\theta)$  的方差有限的无偏估计量的集合.

$U_0 \triangleq \{T : E_{\theta}(T) = 0, D_{\theta}(T) < \infty, \text{ 对一切 } \theta \in \Theta\}$ , 为数学期望为零, 方差有限的估计量的集合.

## 第二节 估计量的优良性准则

**2.定理:** 设  $T_1 \in U$ , 则  $T_1$  是  $g(\theta)$  的一致最小方差无偏估计的充要条件为: 对一切  $\theta \in \Theta$  和  $T_0 \in U_0$ , 有  $E_\theta(T_1 T_0) = 0$ .

**3.推论:** 设  $T_1, T_2$  分别是参数  $\theta$  的可估函数  $g_1(\theta), g_2(\theta)$  的一致最小方差无偏估计量, 则  $b_1 T_1 + b_2 T_2$  是  $b_1 g_1(\theta) + b_2 g_2(\theta)$  的一致最小方差无偏估计量, 其中  $b_1, b_2$  为固定常数.

**4.定理:**  $U \triangleq \{T : E_\theta(T) = g(\theta), \text{Var}_\theta(T) < \infty, \forall \theta \in \Theta\}$ , 则至多存在一个  $g(\theta)$  的一致最小方差无偏估计量.

## 第二节 估计量的优良性准则

### 三.相合估计量

**1.定义：** 设  $T_n = T_n(X_1, \dots, X_n)$  是  $g(\theta)$  的估计量, 若对任何  $\theta \in \Theta$ ,  $T_n$  依概率收敛于  $g(\theta)$ , 则称  $T_n$  是  $g(\theta)$  的相合估计。

**注：** (1) 另一种表述:  $\forall \varepsilon > 0, \lim_{n \rightarrow \infty} P\{|T_n - g(\theta)| \geq \varepsilon\} = 0$ .

(2) 相合性是在极限意义下引入的, 适用大样本情况。

(3) 若  $T_n$  以概率1(几乎处处)收敛于  $g(\theta)$ , 即  $P_\theta\{\lim_{n \rightarrow \infty} T_n(X_1, \dots, X_n) = g(\theta)\} = 1$ , 则称  $T_n$  是  $g(\theta)$  的强相合估计。

(4) 若  $T_n$  是  $g(\theta)$  的强相合估计, 它也是  $g(\theta)$  的相合估计。

## 第二节 估计量的优良性准则

### 2.证明相合估计的方法

定义, 利用切比雪夫不等式  $P\{|X - EX| \geq \varepsilon\} \leq \frac{DX}{\varepsilon^2}$ .



## 第二节 估计量的优良性准则

**例5:** 设总体 $X$ 服从均匀分布,密度函数为

$$f(x; \theta) = \begin{cases} \frac{1}{\theta}, & 0 < x < \theta; \\ 0, & \text{其它}, \end{cases}$$

$(X_1, \dots, X_n)$ 是取自这个总体的一个样本, 证明:  $\hat{\theta} = X_{(n)}$ 是 $\theta$ 的相合估计。

解:  $\hat{\theta} = X_{(n)}$ 的密度函数为

$$f_n(x; \theta) = \begin{cases} n\left(\frac{x}{\theta}\right)^{n-1} \frac{1}{\theta} = \frac{n}{\theta^n} x^{n-1}, & 0 < x < \theta; \\ 0, & \text{其它}, \end{cases}$$

$$E(\hat{\theta}) = \int_0^\theta x \cdot \frac{n}{\theta^n} x^{n-1} dx = \frac{n}{n+1} \theta,$$

$$E(\hat{\theta}^2) = \int_0^\theta x^2 \cdot \frac{n}{\theta^n} x^{n-1} dx = \frac{n}{n+2} \theta^2,$$

$$D(\hat{\theta}) = E(\hat{\theta}^2) - [E(\hat{\theta})]^2 = \frac{n}{n+2} \theta^2 - \left[\frac{n}{n+1} \theta\right]^2 = \frac{n}{(n+1)^2(n+2)} \theta^2$$

## 第二节 估计量的优良性准则

$$\begin{aligned} P\{|\hat{\theta} - \theta| \geq \varepsilon\} &= P\left\{\left|\hat{\theta} - \frac{n}{n+1}\theta - \frac{1}{n+1}\theta\right| \geq \varepsilon\right\} \\ &\leq P\left\{\left|\hat{\theta} - \frac{n}{n+1}\theta\right| + \frac{1}{n+1}\theta \geq \varepsilon\right\} \\ &= P\left\{\left|\hat{\theta} - \frac{n}{n+1}\theta\right| \geq \varepsilon - \frac{1}{n+1}\theta\right\} \\ &= P\left\{\left|\hat{\theta} - E(\hat{\theta})\right| \geq \varepsilon - \frac{1}{n+1}\theta\right\} \\ &\leq \frac{D(\hat{\theta})}{\left(\varepsilon - \frac{1}{n+1}\theta\right)^2} \\ &= \frac{n\theta^2}{(n+1)^2(n+2)\left(\varepsilon - \frac{1}{n+1}\theta\right)^2} \\ &\longrightarrow 0, n \rightarrow \infty \end{aligned}$$

## 第二节 估计量的优良性准则

**3.定理:** 设 $(X_1, \dots, X_n)$ 是取自具有分布族 $\{F(x; \theta) : \theta \in \Theta\}$ 的总体 $X$ 的一个样本, 若 $E|X|^p < \infty$ , 其中 $p$ 是某一正整数, 则样本的 $k$ 阶原点矩 $(1 \leq k \leq p)$   $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ 是总体 $k$ 阶矩 $\alpha_k = EX^k$ 的相合估计.

**4.定理:** 如果 $T_n$ 是 $\theta$ 的相合估计量,  $g(x)$ 在 $x = \theta$ 连续, 则 $g(T_n)$ 也是 $g(\theta)$ 的相合估计量.

## 第三节 Rao-Cramer 不等式

## 第三节 Rao-Cramer 不等式

## 第三节 Rao-Cramer 不等式

### 一. Rao-Cramer 不等式

1. 定义：若单参数分布密度族(或单参数概率分布族) $\{f(x; \theta) : \theta \in \Theta\}$ 满足如下条件：

- (1) 参数空间 $\Theta$ 是数轴上的一个开区间；
- (2) 导数 $\frac{\partial f(x; \theta)}{\partial \theta}$ 对一切 $\theta \in \Theta$ 都存在；
- (3) 集合 $S_\theta \stackrel{\Delta}{=} \{x : f(x; \theta) > 0\}$ 与 $\theta$ 无关( $S_\theta$ 称为支撑)；
- (4)  $\frac{\partial}{\partial \theta} \int f(x; \theta) dx = \int \frac{\partial f(x; \theta)}{\partial \theta} dx = 0$ , 对一切 $\theta \in \Theta$ ；
- (5) 对任 $\theta \in \Theta$ , 有

$$\begin{aligned} 0 < I(\theta) &\stackrel{\Delta}{=} E_\theta \left[ \frac{\partial}{\partial \theta} \log f(X; \theta) \right]^2 \\ &= \int \left( \frac{\partial \log f(x; \theta)}{\partial \theta} \right)^2 f(x; \theta) dx, \end{aligned}$$

则称这个分布密度族(概率分布族)为Rao-Cramer 正则分布族, 其中条件(1)–(5) 称为正则条件,  $I(\theta)$ 称为该分布密度族的Fisher信息函数

### 第三节 Rao-Cramer 不等式

**例1:** 验证Poisson分布族

$\{f(x; \lambda) = \frac{\lambda^x}{x!} e^{-\lambda}, x = 0, 1, 2, \dots; \lambda > 0\}$  是Rao-Cramer正则分布族.

解: (1) 参数空间 $\{\lambda > 0\}$ 是一开区间;

(2)  $\frac{\partial f(x; \theta)}{\partial \lambda} = \frac{\lambda^{x-1}}{x!} (x - \lambda) e^{-\lambda}$ , 对一切 $\lambda > 0$ 存在;

(3)  $f(x; \lambda) > 0$ , 对一切非负整数 $x$ 及 $\lambda$ 成立;

(4)

$$\sum_{x=0}^{\infty} \frac{\lambda^{x-1}}{x!} (x - \lambda) e^{-\lambda} = \sum_{x=1}^{\infty} \frac{\lambda^{x-1}}{(x-1)!} e^{-\lambda} - \sum_{x=0}^{\infty} \frac{\lambda^x}{x!} e^{-\lambda} = 1 - 1 = 0;$$

(5)  $\log f(x; \lambda) = x \log \lambda - \log x! - \lambda$ ,  $\frac{\partial \log f(x; \lambda)}{\partial \lambda} = \frac{x}{\lambda} - 1$ , 因此

$$E_{\lambda} \left[ \frac{\partial \log f(X; \lambda)}{\partial \lambda} \right] = 0, I(\lambda) = E_{\lambda} \left[ \frac{\partial \log f(X; \lambda)}{\partial \lambda} \right]^2 = D_{\lambda} \left( \frac{X}{\lambda} - 1 \right) = \frac{1}{\lambda},$$

故Poisson分布族是Rao-Cramer正则分布族.

### 第三节 Rao-Cramer 不等式

**例2:** 正态分布族  $\{N(\mu, 1) : -\infty < \mu < \infty\}$  是 Rao-Cramer 正则分布族.

**解:** 对所考虑的正态分布密度

$$f(x; \mu) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(x-\mu)^2},$$

条件(1)-(4)是显然满足的, 只需验证条件(5)也满足. 事实上, 由于

$$\frac{\partial \log f(x; \mu)}{\partial \mu} = x - \mu,$$

故

$$E_{\mu} \left[ \frac{\partial \log f(X; \mu)}{\partial \mu} \right]^2 = E_{\mu} (X - \mu)^2 = D_{\mu} X = 1.$$

所以正态分布族  $\{N(\mu, 1) : -\infty < \mu < \infty\}$  是 Rao-Cramer 正则分布族.

### 第三节 Rao-Cramer 不等式

注:

(1)常用的单参数分布族都是Rao-Cramer正则分布族,但均匀分布族 $\{U(0, \theta) : \theta > 0\}$ 不是Rao-Cramer正则分布族,因为它的支撑 $S_\theta = \{x : f(x; \theta) > 0\}$ 是一个依赖于 $\theta$ 的开区间。

(2)计算 $I(\theta)$ 的一个简便方法:  $I(\theta) = -E_\theta \left( \frac{\partial^2 \log f(X; \theta)}{\partial \theta^2} \right)$



## 第三节 Rao-Cramer 不等式

**2.定理: (Rao-Cramer不等式)** 设总体 $X$ 的概率分布密度族 $\{f(x; \theta) : \theta \in \Theta\}$ 是Rao-Cramer正则分布族,可估函数 $g(\theta)$ 是 $\Theta$ 上的可微函数, $(X_1, \dots, X_n)$ 是取自总体 $X$ 的一个样本.若 $T(X_1, \dots, X_n)$ 是 $g(\theta)$ 的一个无偏估计量,且对一切 $\theta \in \Theta$ ,满足

$$\begin{aligned} & \frac{\partial}{\partial \theta} \int T(x_1, \dots, x_n) L(x_1, \dots, x_n; \theta) dx_1 \cdots dx_n \\ &= \int T(x_1, \dots, x_n) \frac{\partial}{\partial \theta} L(x_1, \dots, x_n; \theta) dx_1 \cdots dx_n, \end{aligned} \quad (*)$$

其中 $L(x_1, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta)$ 是样本 $(X_1, \dots, X_n)$ 的联合分布密度函数. 则对一切 $\theta \in \Theta$ ,有

$$D_{\theta}(T) \geq \frac{[g'(\theta)]^2}{nI(\theta)} \quad (1)$$

其中 $I(\theta)$ 是该分布族的Fisher信息函数.

### 第三节 Rao-Cramer 不等式

特别当  $g(\theta) = \theta$  时,  $D_{\theta}(T) \geq \frac{1}{nI(\theta)}$ .

如果(1)中等号成立, 则  $\exists C(\theta) \neq 0$ , s.t.

$$\frac{\partial \ln L(x_1, \dots, x_n; \theta)}{\partial \theta} = C(\theta)[T(x_1, \dots, x_n) - g(\theta)] \text{ a.s.}$$

注: (1)称满足上述定理中正则条件的估计量  $T$  为正规估计量。

(2)称Rao—Cramer不等式所规定的下界为**C—R**下界。

(3)若一个无偏估计  $T$  的方差达到这个下界, 且  $g(\theta)$  的一切无偏估计都满足条件(\*), 则  $T$  就是  $g(\theta)$  的UMVUE。

(4)离散性总体: 密度函数  $\rightarrow$  概率分布, 积分  $\rightarrow$  求和

### 第三节 Rao-Cramer 不等式

(5)  $nI(\theta)$  越大,  $\text{Var}_{\theta}(T)$  可达下界越低, 即  $g(\theta)$  可能被估计得越准确. 所以  $I(\theta)$  在一定意义上表示对  $X$  进行观测所提供的关于未知参数  $\theta$  的平均信息.

(6) C-R 不等式只对 C-R 正则族成立. 如定理中条件之一不满足, C-R 不等式可能不成立.

### 第三节 Rao-Cramer 不等式

例：设  $(X_1, \dots, X_n)$  是总体  $X$  的一个样本， $X$  的密度函数为

$$f(x; \theta) = e^{-(x-\theta)}, x > \theta.$$

因为  $\{x : f(x; \theta) > 0\} = \{x > \theta\}$ ，所以不是 C-R 正则族。

形式上计算 C-R 下界：

$$I(\theta) = E \left[ \frac{\partial \ln f(X; \theta)}{\partial \theta} \right]^2 = E(1) = 1, \text{ 下界 } \frac{1}{n}$$

$$\hat{\theta} = X_{(1)} - \frac{1}{n}, \quad f(t; \theta) = ne^{-(nt-n\theta+1)}, \quad t > \theta - \frac{1}{n}.$$

$$E(\hat{\theta}) = \theta, \quad E(\hat{\theta}^2) = \theta^2 + \frac{1}{n^2}, \quad D(\hat{\theta}) = \frac{1}{n^2} < \frac{1}{n}$$

### 第三节 Rao-Cramer 不等式

例: 设  $(X_1, \dots, X_n)$  是总体  $X$  的一个样本,  $X$  的密度函数为

$$f(x; \theta) = e^{-(x-\theta)}, x > \theta.$$

因为  $\{x : f(x; \theta) > 0\} = \{x > \theta\}$ , 所以不是 C-R 正则族.  
形式上计算 C-R 下界:

$$I(\theta) = E \left[ \frac{\partial \ln f(X; \theta)}{\partial \theta} \right]^2 = E(1) = 1, \text{ 下界 } \frac{1}{n}$$

$$\hat{\theta} = X_{(1)} - \frac{1}{n}, \quad f(t; \theta) = ne^{-(nt-n\theta+1)}, \quad t > \theta - \frac{1}{n}.$$

$$E(\hat{\theta}) = \theta, \quad E(\hat{\theta}^2) = \theta^2 + \frac{1}{n^2}, \quad D(\hat{\theta}) = \frac{1}{n^2} < \frac{1}{n}$$

### 第三节 Rao-Cramer 不等式

例3: 设总体  $X$  具有 Bernoulli 分布

族  $\{b(1, p) : p \in (0, 1)\}$ ,  $(X_1, \dots, X_n)$  是取自这一总体的样本, 求  $p$  的正规无偏估计的方差下界.

解: 容易验证 Bernoulli 分布族是 Rao-Cramer 正则分布族, 有

$$f(x; p) = p^x(1-p)^{1-x}, \quad x = 0, 1, \quad 0 < p < 1,$$

且

$$I(p) = \sum_{x=0}^1 \left[ \frac{\partial \log f(x; p)}{\partial p} \right]^2 f(x; p) = \frac{1}{p(1-p)},$$

故  $p$  的正规无偏估计的方差下界为

$$\frac{1}{nI(p)} = \frac{p(1-p)}{n}.$$

$\hat{p} = \bar{X}$  是  $p$  的无偏估计, 而  $D(\bar{X}) = \frac{p(1-p)}{n}$  达到 Rao-Cramer 不等式的下界.

### 第三节 Rao-Cramer 不等式

例3: 设总体  $X$  具有 Bernoulli 分布

族  $\{b(1, p) : p \in (0, 1)\}$ ,  $(X_1, \dots, X_n)$  是取自这一总体的样本, 求  $p$  的正规无偏估计的方差下界.

解: 容易验证 Bernoulli 分布族是 Rao-Cramer 正则分布族, 有

$$f(x; p) = p^x(1-p)^{1-x}, \quad x = 0, 1, \quad 0 < p < 1,$$

且

$$I(p) = \sum_{x=0}^1 \left[ \frac{\partial \log f(x; p)}{\partial p} \right]^2 f(x; p) = \frac{1}{p(1-p)},$$

故  $p$  的正规无偏估计的方差下界为

$$\frac{1}{nI(p)} = \frac{p(1-p)}{n}.$$

$\hat{p} = \bar{X}$  是  $p$  的无偏估计, 而  $D(\bar{X}) = \frac{p(1-p)}{n}$  达到 Rao-Cramer 不等式的下界.

### 第三节 Rao-Cramer 不等式

**例4:** 设 $X$ 的密度函数为  $f(x; \lambda) = \begin{cases} \lambda e^{-\lambda x}, & x > 0; \\ 0, & x \leq 0, \end{cases}$ ,

$(X_1, \dots, X_n)$  是取自总体 $X$ 的样本, 未知参数  $\lambda > 0$ , 求待估函数  $u(\lambda) = \frac{1}{\lambda}$  的正规无偏估计量的C-R下界.

解: 指数分布族是Rao-Cramer正则分布族, 且当  $x > 0$  时,

$$\log f(x; \lambda) = -\lambda x + \log \lambda$$

$$\frac{\partial^2 \log f(x; \lambda)}{\partial \lambda^2} = \frac{\partial^2 (-\lambda x + \log \lambda)}{\partial \lambda^2} = \frac{\partial}{\partial \lambda} \left( -x + \frac{1}{\lambda} \right) = -\frac{1}{\lambda^2}$$

$$\text{所以 } I(\lambda) = -E\left(\frac{\partial^2 \log f(X; \lambda)}{\partial \lambda^2}\right) = -E\left(-\frac{1}{\lambda^2}\right) = \frac{1}{\lambda^2}$$

$$\text{C-R下界: } \frac{[u'(\lambda)]^2}{nI(\lambda)} = \frac{1}{n\lambda^2}.$$

$$E(\bar{X}) = E(X) = \frac{1}{\lambda} = u(\lambda), \quad D(\bar{X}) = \frac{1}{n} D(X) = \frac{1}{n} \frac{1}{\lambda^2} = \frac{1}{n\lambda^2},$$

$\bar{X}$  的方差达到C-R下界.



### 第三节 Rao-Cramer 不等式

**例4:** 设 $X$ 的密度函数为  $f(x; \lambda) = \begin{cases} \lambda e^{-\lambda x}, & x > 0; \\ 0, & x \leq 0, \end{cases}$ ,

$(X_1, \dots, X_n)$  是取自总体 $X$ 的样本, 未知参数  $\lambda > 0$ , 求待估函数  $u(\lambda) = \frac{1}{\lambda}$  的正规无偏估计量的C-R下界.

解: 指数分布族是Rao-Cramer正则分布族, 且当  $x > 0$  时,

$$\log f(x; \lambda) = -\lambda x + \log \lambda$$

$$\frac{\partial^2 \log f(x; \lambda)}{\partial \lambda^2} = \frac{\partial^2 (-\lambda x + \log \lambda)}{\partial \lambda^2} = \frac{\partial}{\partial \lambda} \left( -x + \frac{1}{\lambda} \right) = -\frac{1}{\lambda^2}$$

$$\text{所以 } I(\lambda) = -E\left(\frac{\partial^2 \log f(X; \lambda)}{\partial \lambda^2}\right) = -E\left(-\frac{1}{\lambda^2}\right) = \frac{1}{\lambda^2}$$

$$\text{C-R下界: } \frac{[u'(\lambda)]^2}{nI(\lambda)} = \frac{1}{n\lambda^2}.$$

$$E(\bar{X}) = E(X) = \frac{1}{\lambda} = u(\lambda), \quad D(\bar{X}) = \frac{1}{n} D(X) = \frac{1}{n} \frac{1}{\lambda^2} = \frac{1}{n\lambda^2},$$

$\bar{X}$  的方差达到C-R下界.

## 第三节 Rao-Cramer 不等式

### 二.有效估计量

1.定义：设总体 $X$ 的概率分布密度

族 $\{f(x; \theta) : \theta \in \Theta\}$ 是Rao-Cramer正则分布族, $g(\theta)$ 是可估函数,  
 $T = T(X_1, \dots, X_n)$ 是 $g(\theta)$ 的估计量.

(1)若 $E_{\theta}(T) = g(\theta)$ ,则称

$$e_{\theta}(T) = \frac{[g'(\theta)]^2}{nI(\theta)} / D_{\theta}(T)$$

为 $g(\theta)$ 的无偏估计量 $T$ 的效率.

(2)若 $E_{\theta}(T) = g(\theta)$ ,且 $e_{\theta}(T) = 1$ ,则称 $T$ 为 $g(\theta)$ 的有效估计量.

(3)设 $T_n = T_n(X_1, \dots, X_n)$ 是 $g(\theta)$ 的一列无偏估计,若

$$\lim_{n \rightarrow \infty} e_{\theta}(T_n) = e_0,$$

则称 $e_0$ 为 $T_n$ 的渐近效率;当 $e_0 = 1$ 时,称 $T_n$ 是 $g(\theta)$ 的渐近有效估计.

### 第三节 Rao-Cramer 不等式

**例5:** 设 $X$ 服从 $\Gamma(r, \frac{1}{\lambda})$ , 即

$$f(x; \theta) = \begin{cases} \frac{1}{\lambda^r \Gamma(r)} x^{r-1} e^{-\frac{x}{\lambda}}, & x > 0; \\ 0, & x \leq 0, \end{cases}$$

其中 $r > 0$ 已知,  $\lambda > 0$ 未知,  $(X_1, \dots, X_n)$ 为 $X$ 的样本, 证明:  $\frac{1}{nr} \sum_{i=1}^n X_i$  是 $\lambda$ 的有效估计。

**证:** 因为 $E(\frac{1}{nr} \sum_{i=1}^n X_i) = \frac{1}{nr} nr \lambda = \lambda$ , 所以 $\frac{1}{nr} \sum_{i=1}^n X_i$ 是 $\lambda$ 的无偏估计。

验证条件, 它是Rao-Cramer正则分布

族,  $\ln f(x, \lambda) = -r \ln \lambda - \ln \Gamma(r) + (r-1) \ln x - \frac{x}{\lambda}$ , 则

$$\frac{\partial \ln f(x; \lambda)}{\partial \lambda} = -\frac{r}{\lambda} + \frac{x}{\lambda^2}, \quad \frac{\partial^2 \ln f(x; \lambda)}{\partial \lambda^2} = \frac{r}{\lambda^2} - \frac{2x}{\lambda^3}$$

### 第三节 Rao-Cramer 不等式

**例5:** 设 $X$ 服从 $\Gamma(r, \frac{1}{\lambda})$ , 即

$$f(x; \theta) = \begin{cases} \frac{1}{\lambda^r \Gamma(r)} x^{r-1} e^{-\frac{x}{\lambda}}, & x > 0; \\ 0, & x \leq 0, \end{cases}$$

其中 $r > 0$ 已知,  $\lambda > 0$ 未知,  $(X_1, \dots, X_n)$ 为 $X$ 的样本, 证明:  $\frac{1}{nr} \sum_{i=1}^n X_i$  是 $\lambda$ 的有效估计。

**证:** 因为 $E(\frac{1}{nr} \sum_{i=1}^n X_i) = \frac{1}{nr} nr\lambda = \lambda$ , 所以 $\frac{1}{nr} \sum_{i=1}^n X_i$ 是 $\lambda$ 的无偏估计。

验证条件, 它是Rao-Cramer正则分布

族,  $\ln f(x, \lambda) = -r \ln \lambda - \ln \Gamma(r) + (r-1) \ln x - \frac{x}{\lambda}$ , 则

$$\frac{\partial \ln f(x; \lambda)}{\partial \lambda} = -\frac{r}{\lambda} + \frac{x}{\lambda^2}, \quad \frac{\partial^2 \ln f(x; \lambda)}{\partial \lambda^2} = \frac{r}{\lambda^2} - \frac{2x}{\lambda^3}$$

### 第三节 Rao-Cramer 不等式

所以

$$I(\lambda) = -E\left(\frac{r}{\lambda^2} - \frac{2X}{\lambda^3}\right) = -\frac{r}{\lambda^2} + \frac{2\lambda r}{\lambda^3} = \frac{r}{\lambda^2}$$

所以C-R下界为  $\frac{1}{nI(\lambda)} = \frac{1}{n \frac{r}{\lambda^2}} = \frac{\lambda^2}{nr}$

而  $D\left(\frac{1}{nr} \sum_{i=1}^n X_i\right) = \frac{1}{n^2 r^2} \sum_{i=1}^n D(X_i) = \frac{nr\lambda^2}{n^2 r^2} = \frac{\lambda^2}{nr}$  达到C-R下界,  
所以  $\frac{1}{nr} \sum_{i=1}^n X_i$  是  $\lambda$  的有效估计。

## 第三节 Rao-Cramer 不等式

2.定义：对可估函数 $g(\theta)$ 的任意两个无偏估计量 $T_1$ 和 $T_2$ ，称

$$e(T_1|T_2) = \frac{D_{\theta}(T_1)}{D_{\theta}(T_2)}$$

为估计量 $T_1$ 关于 $T_2$ 的相对效率；如果 $e(T_1|T_2) < 1$ ，则称 $T_1$ 比 $T_2$ 有效。

注：也就是若 $D(T_1) < D(T_2)$ ，则 $T_1$ 比 $T_2$ 有效。

## 第四节 Rao-Blackwell定理

**1.定理(Rao-Blackwell定理)** 设  $T(X_1, \dots, X_n)$  是分布族  $\{F(x; \theta) : \theta \in \Theta\}$  的一个充分统计量,  $V$  是  $g(\theta)$  的一个无偏估计量, 则

$$V_0 = V_0(T) = E(V|T)$$

是  $g(\theta)$  的一个无偏估计量且  $\text{Var}_\theta(V_0) \leq \text{Var}_\theta(V), \forall \theta \in \Theta$ . 其中等号成立的充要条件是  $V$  在 a.s. 意义下是  $T$  的函数.

## 第四节 Rao-Blackwell 定理

- 注: (1) 定理提供了一种改善估计的方法, 若已知一无偏估计量, 则可构造一新的无偏估计量且其方差比原估计量的方差小;
- (2) 一致最小方差无偏估计量(UMVUE)一定是充分统计量的函数, 否则按定理的方法可构造比原估计量有更小方差的估计;
- (3) 若 $g(\theta)$ 的由充分统计量构造的无偏估计量是a.s.唯一的, 则此无偏估计量一定是一致最小方差无偏估计量.
- (4) 由充分统计量构造的无偏估计量为充分无偏估计量.



## 第四节 Rao-Blackwell 定理

**2.定理** 在Rao-Cramer正则条件下,  $g(\theta)$ 的无偏估计量  $T(X_1, \dots, X_n)$ 是有效估计量, 则  $T(X_1, \dots, X_n)$ 是充分统计量.

**3.定理(Lehmann-Scheffe定理)** 设  $(X_1, \dots, X_n)$ 是取自分布族  $\{F(x; \theta) : \theta \in \Theta\}$ 的一个样本,  $T(X_1, \dots, X_n)$ 是 $\theta$ 的充分完备统计量. 如果一个只依赖于  $T(X_1, \dots, X_n)$ 的估计量  $h[T(X_1, \dots, X_n)]$ 为  $g(\theta)$ 的无偏估计, 则它是  $g(\theta)$ 的唯一的一致最小方差无偏估计量.

## 第四节 Rao-Blackwell 定理

**例1:** 设 $(X_1, \dots, X_n)$ 是取自两点分布族 $\{b(1, p) : 0 < p < 1\}$ 的一个样本, 求 $p$ 的一致最小方差无偏估计量.

**例2:** 设 $(X_1, \dots, X_n)$ 是取自均匀分布族 $\{U(0, \theta) : 0 < \theta < 1\}$ 的一个样本, 求 $\theta$ 的一致最小方差无偏估计量.

**例3:** 设 $(X_1, \dots, X_n)$ 是取自参数为 $\lambda$ 的Poisson分布的一个样本, 其中 $\lambda > 0$ 为未知参数, 求 $P_\lambda(k) = \frac{\lambda^k}{k!} e^{-\lambda}, k = 0, 1, 2, \dots$ 的一致最小方差无偏估计量.